
Непрерывное время при построении нейроинтерфейса BCI

A Preprint

Змушко Филипп
МФТИ
zmushko.fa@phystech.edu

Самохина Алина
МФТИ
alina.samokhina@phystech.edu

Стрижов Вадим
МФТИ
strijov@phystech.edu

Abstract

В задачах декодирования сигнала непрерывный процесс исследуется с помощью рекуррентных нейронных сетей, использующих дискретное представление о времени. Недавно появившиеся модели, основывающиеся на нейронных обыкновенных дифференциальных уравнениях рассматривают временные ряды как непрерывные во времени. В данной работе исследуется задача декодирования сигнала через представление в виде непрерывной во времени функции. Проводится сравнение базовых моделей, использующих дискретное время, с моделями на основе нейронных дифференциальных уравнений: обыкновенных и управляемых. Исследуется применение данных моделей как для регулярных сигналов, так и для сигналов с пропущенными значениями.

Keywords Нейронные ОДУ · Управляемые ДУ · временные ряды · классификация

1 Введение

Данная статья посвящена использованию непрерывного по времени сигнала при построении интерфейса мозг-компьютер (ИМК). ИМК — технология, позволяющая человеку взаимодействовать с компьютером посредством обработки данных об электрической активности мозга. В данной работе рассматривается задача классификации электроэнцефалограмм (ЭЭГ). Основной сложностью при работе с сигналами ЭЭГ является зашумленность и нерегулярный шаг по временной сетке. Это происходит из-за того, что обычно данные устройства предназначены для массового употребления, и, как следствие, имеют малое число датчиков и низкую частоту дискретизации сигнала. Для решения данной проблемы предлагается использовать модели на основе непрерывного представления сигнала во времени.

Большинство моделей такого типа основывается идее нейронных дифференциальных уравнений. Данная концепция базируется на схожести формулы для скрытого состояния блока ResNet с формулой Эйлера для решения обыкновенных дифференциальных уравнений (ODE). Эта идея, изложенная в [2], рассматривает скрытое состояние ResNet как непрерывное во времени. Дальнейшее развитие этой концепции привело к появлению целого класса моделей, использующих непрерывное представление времени в рекуррентных нейронных сетях. В [5] рассматривается непрерывный аналог LSTM. Применение нейронных ОДУ к временным рядам с нерегулярным шагом по временной сетке представлено в [3]. В [6] авторы рассматривают непрерывное представление во времени в виде разложения на полиномы Лежандра. Использование нейронных ОДУ в байесовских моделях исследуется в [7].

В данной работе рассмотрено использование вышеперечисленных моделей в задаче декодирования сигнала. Изучены применения данных моделей для решения следующих задач:

- построение нейроинтерфейса, работающего с непрерывным представлением о времени
- обработка нерегулярных во времени сигналов
- получение непрерывного представления сигнала

Сравнение моделей на основе NODE, а также базовых моделей (RNN, EEGNet[4], ERPCov TS LR[1]), использующих дискретное представление времени, производится в рамках задачи классификации на

наборе данных потенциалов Р300. Рассматриваемые здесь потенциалы Р300 — вызванные потенциалы, являющиеся специфическим откликом электрической активности мозга в ответ на внешний стимул.

Вышеперечисленные модели работают с непрерывным представлением временных рядов, но при этом не используют свойство непрерывности сигнала. В данной работе исследуется получение непрерывного представления сигнала, которое в дальнейшем может быть использовано при построении новых признаков пространств. Эти представления могут рассматриваться как скрытые пространства, которые используются для согласования исходного сигнала с прогнозом с помощью корреляционного анализа.

2 Постановка задачи

2.1 Задача классификации сигнала

Рассматривается задача классификации на выборке из регулярных по времени данных. Выборка делится на две части: обучающую и валидационную в соотношении 80:20.

Пусть, в выборке присутствует M наблюдений. Тогда сигнал и целевая переменная определяются следующим образом:

$$\mathbf{X} = \{\mathbf{X}_i\}_{i=1}^M,$$

$$\mathbf{X}_i = \{\mathbf{x}_t\}_{t \in T}, \mathbf{x}_t \in \mathbb{R}^E, T = \{t_i\}_{i=1}^N, t_i \in \mathbb{R}$$

$$\mathbf{Y} = \{y_i\}_{i=1}^M, y_i \in \{0, 1\}$$

E — количество электродов

N — количество наблюдений в одном отрезке ЭЭГ

Постановка задачи классификации. В парадигме Р300 решается задача бинарной классификации отрезков ЭЭГ. Задача — определить наличие в отрезке ЭЭГ потенциала Р300.

Для данных, рассмотренных в двух предыдущих разделах, требуется получить целевую функцию:

$$g_\theta : \mathbf{X} \rightarrow \mathbf{Y}.$$

Критерием качества в данной задаче является бинарная кросс-энтропия:

$$L = -\frac{1}{M} \sum_{m=1}^M \left[y_m \log p_m + (1 - y_m) \log(1 - p_m) \right]$$

$$p_m = g_\theta(\mathbf{X}_m) \text{ — вероятность 1 класса для } \mathbf{X}_m$$

Решается оптимизационная задача:

$$\hat{\theta} = \arg \max_{\theta} L(\theta, \mathbf{X}).$$

Внешними критериями качества для задачи классификации являются точность и F1-score.

2.2 Построение непрерывного представления сигнала

Еще одной задачей данной работы является получение непрерывного представления сигнала. Пусть, имеется непрерывный процесс (активность мозга, движение):

$$V(t), t \in \mathbb{R}$$

Тогда данные выборки, регистрируемый сигнал — реализация процесса $V(t)$:

$$\mathbf{X} = \{\mathbf{x}_t\}_{t \in T}, \mathbf{x}_t \in \mathbb{R}^E, T = \{t_i\}_{i=1}^N, t_i \in \mathbb{R}$$

$$\mathbf{x}_{t_i} \approx V(t_i).$$

Предполагается, что можно получить:

$$f_{\mathbf{X}}(t) : \mathbb{R} \rightarrow \mathbb{R}^E, f_{\mathbf{X}}(t) = \mathbf{x}_t \approx V(t).$$

В данной работе построение непрерывного представления рассматривается в рамках решения задачи классификации сигналов. Непрерывное представление извлекается из скрытых состояний рассматриваемых далее алгоритмов классификации.

Список литературы

- [1] Alexandre Barachant, Stéphane Bonnet, Marco Congedo, and Christian Jutten. Multiclass brain–computer interface classification by riemannian geometry. *IEEE Transactions on Biomedical Engineering*, 59(4):920–928, 2012.
- [2] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.
- [3] Patrick Kidger, James Morrill, James Foster, and Terry J. Lyons. Neural controlled differential equations for irregular time series. In *NeurIPS*, 2020.
- [4] Vernon J. Lawhern, Amelia J. Solon, Nicholas R. Waytowich, Stephen M. Gordon, Chou Po Hung, and Brent Lance. Eegnet: A compact convolutional network for eeg-based brain-computer interfaces. *Journal of neural engineering*, 15 5:056013, 2018.
- [5] Mathias Lechner and Ramin Hasani. Learning long-term dependencies in irregularly-sampled time series. *arXiv preprint arXiv:2006.04418*, 2020.
- [6] Aaron Voelker, Ivana Kajić, and Chris Eliasmith. Legendre memory units: Continuous-time representation in recurrent neural networks. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [7] Cagatay Yildiz, Markus Heinonen, and Harri Lahdesmaki. Ode2vae: Deep generative second order odes with bayesian neural networks. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.